

Yapay Zeka Destekli Veri Seti Hipotez Öneri Sistemi

Beyza Karagöz

Bilgisayar Mühendisliği Bölümü
Kastamonu Üniversitesi

<https://orcid.org/0009-0007-9608-4681>

Özet—Bu çalışmada, akademik performans analizi ve otomatik hipotez üretimi amacıyla yapay zekâ destekli bir sistem geliştirilmiş ve çeşitli açılardan değerlendirilmiştir. Sistem; haftalık çalışma saati, devamsızlık sayısı ve sınav puanı gibi akademik performans göstergelerini girdi olarak almakta ve bu verileri işleyerek anlamlı akademik hipotezler, güven skorları, performans kategorileri ile kişiselleştirilmiş öneriler üretmektedir. Bu süreç, birden fazla aşamadan oluşan otomatik bir işleme yapısı üzerinden yürütülmektedir. Sistem altyapısı n8n açık kaynaklı otomasyon platformu üzerinde kurulmuş, modern bir tek sayfa web uygulamasıyla ise RESTful webhook API aracılığıyla haberleşecek şekilde yapılandırılmıştır. Sentetik öğrenci profilleri üzerinde yapılan deneylerde, kategori sınıflandırmasında %93,3 doğruluk oranına, 82,9 ortalama güven skoruna ve gerçek zamanlı kullanım açısından kabul edilebilir düzeyde 1,22 saniye ortalama uçtan uca yanıt süresine ulaşılmıştır. Elde edilen bulgular, sistemin akademik performans verilerinin yorumlanması ve öneri üretilmesi açısından kullanılabilir bir yaklaşım sunduğunu göstermektedir.

Anahtar Kelimeler—yapay zeka; hipotez önerisi; akademik performans analizi; n8n workflow otomasyonu; webhook API; özellik analizi; güven skoru; eğitimsel karar destek sistemi

I. GİRİŞ

Akademik performans tahmini ve izlenmesi, eğitim veri madenciliği (EVM) ve öğrenme analitiği (OA) alanlarında önemli araştırma konularından biri haline gelmiştir. Doğrusal regresyon ve kural tabanlı notlandırma sistemleri gibi geleneksel yöntemler, öğrenci davranış verilerindeki karmaşık ve doğrusal olmayan ilişkileri her zaman yeterli düzeyde açıklayamamaktadır [1]. Büyük dil modelleri (BDM) ve workflow otomasyon platformlarında yaşanan hızlı gelişmeler ise, eğitim alanında daha akıllı ve otomatik karar destek sistemlerinin geliştirilmesini mümkün kılmaktadır [2].

Bu çalışmada geliştirilen yapay zekâ destekli sistem; haftalık çalışma saati, devamsızlık sayısı ve sınav puanı gibi temel akademik performans göstergelerini girdi olarak almakta ve bu verileri n8n tabanlı bir iş akışı üzerinden işleyerek akademik hipotezler, performans kategorileri, güven skorları ve kişiselleştirilmiş önerilere dönüştürmektedir. Sistem, tarayıcı tabanlı bir tek sayfa web uygulaması ile webhook API üzerinden haberleşecek şekilde tasarlanmış ve gerçek zamanlı kullanıcı etkileşimini destekleyecek biçimde yapılandırılmıştır.

Bu çalışmanın temel katkıları arasında; akademik veriye uygun bir veri ön işleme ve özellik çıkarma yapısının geliştirilmesi, gerçek zamanlı iletişim mimarisinin sisteme entegre edilmesi, kural tabanlı puanlama ile BDM tabanlı üretici yaklaşımın birlikte kullanılması ve çıktı belirsizliğini sayısal olarak değerlendiren bir güven skoru mekanizmasının oluşturulması yer almaktadır. Bu yönüyle çalışma, yapay zekâ destekli akademik danışmanlık sistemleri için benzer çalışmalara örnek olabilecek bir uygulama yaklaşımı sunmaktadır.

Makalenin kalan bölümleri şu şekilde düzenlenmiştir: Bölüm II ilgili literatürü, Bölüm III sistem mimarisini, Bölüm IV workflow tasarımını ele almaktadır. Bölüm V ve VI sırasıyla web arayüzü ve yapay zekâ analiz yapısını açıklamakta, sonraki bölümlerde ise

metodoloji, gerçekleştirme, bulgular, tartışma ve sonuç bölümlerine yer verilmektedir.

II. KATKILAR

Bu çalışma, hipotez öneri ve öğrenci destek sistemleri alanında aşağıdaki özgün katkıları sunmaktadır:

Büyük dil modelleri (LLM) ve eğitim analitiğini birleştiren, öğrencilerin akademik performans verilerine dayalı **hipotez öneri tabanlı karar destek mimarisi** önerilmiştir.

Öğrencilerin ders başarı örüntülerini analiz ederek kişiselleştirilmiş öneriler üreten **yapay zekâ destekli öneri mekanizması** geliştirilmiştir.

Geleneksel öğrenci bilgi sistemlerinden farklı olarak, yalnızca veri gösterimi değil aynı zamanda **yorumlama, çıkarım ve öneri üretme yeteneğine sahip akıllı bir sistem yaklaşımı** sunulmuştur. Sistem, bilgisayar mühendisliği eğitiminde kullanılabilecek şekilde tasarlanmış olup, öğrenci performans analitiği ile LLM tabanlı öneri üretimini entegre eden **uygulanabilir bir prototip mimari** ortaya koymaktadır.

Önerilen yaklaşım, gelecekte öğrenme analitiği, adaptif eğitim sistemleri ve eğitim odaklı karar destek sistemleri için genişletilebilir bir altyapı sağlamaktadır.

III. İLGİLİ LİTERATÜR

Öğrenci akademik performansının otomatik tahmini ve yorumlanması, EVM ve OA alanlarında yoğun şekilde incelenmektedir. Romero ve Ventura [3], EVM tekniklerine ilişkin kapsamlı bir derleme sunarak karar ağaçları ile yapay sinir ağlarını not tahmini görevlerinde en yaygın kullanılan modeller olarak ortaya koymuştur. Amrieh ve ark. [4], davranışsal katilim verisi üzerinde topluluk sınıflandırıcı kullanarak %80'in üzerinde sınıflandırma doğruluğu elde ettiklerini gösteris ve makine

ogreniminin risk altındaki öğrencilerin erken tespiti için potansiyelini vurgulamıştır.

Workflow otomasyon platformları açısından değerlendirildiğinde, n8n, Apache Airflow ve Zapier gibi düşük kodlu (low-code) ve kodsuz (no-code) araçlar hem akademik araştırma altyapıları hem de endüstri veri hatlarında giderek daha fazla benimsenilmektedir [5]. Zhao ve ark. [5], görsel workflow motorlarının özelleştirmiş betik tabanlı hatlarla karşılaştırıldığında geliştirme yukunu %60'a kadar düşürebileceğini, buna karşın es değer veri işlem kapasitesi sağlayabileceğini ortaya koymuş; bu durum, özel yazılım mühendisliği ekibine sahip olmayan kaynak kısıtlı eğitim kurumları için bu platformları özellikle cazip kılmaktadır.

Büyük dil modellerinin eğitim destek bağlamına entegrasyonu birçok güncel çalışmada ele alınmıştır. Brown ve ark. [6], GPT-3 modelinin az sayıda örnek (few-shot) genelleme kapasitesini ortaya koyarak tek bir üretici modelin görev özelinde ince ayar yapılmaksızın geri bildirim yazımı ve hipotez formüle etme dahil çeşitli metin üretimi görevlerine uyarlanabildiğini göstermiştir. Zawacki-Richter ve ark. [7], 146 çalışmalı bir derleme yayınlayarak yükseköğretimde yapay zekanın dört temel uygulama alanını belirledi: profilme ve tahmin, akıllı öğretim sistemleri, uyarlamalı sistemler ile değerlendirme ve ölçme. Bu bulgular, kişileştirilmiş akademik öneri üretimi için BDM tabanlı motorların uygulanabilirliğini doğrulamaktadır.

Model kalibrasyonu ve güven tahmini, uygulamalı makine öğrenmesinde aktif bir araştırma alanı olmaya devam etmektedir. Guo ve ark. [8], modern derin sinir ağlarının çoğunlukla asiri güvenli (overconfident) tahminler yaptığını ve sıcaklık ölçeklemesinin kalibrasyonu önemli ölçüde iyileştirdiğini göstermiştir. Bu çalışmada benimsenen analitik güven skoru hesaplama yaklaşımı, veri tutarlılığı, özellik tutarlılığı ve kategori ayırma marjını bağımsız kalibrasyon sinyalleri olarak dahil etmek suretiyle bu bulgulardan esinlenmektedir.

Veri on işleme boyutunda Rahm ve Do [9], veri kalitesi sorunlarını tek kaynaklı ve çok kaynaklı kategorilere ayırmış; sistematik temizleme hatlarının güvenilir model çıktıları için on koşul olduğunu savunmuştur. Workflow içerisine gömülmüş aralık doğrulama, eksik değer işleme ve asiri değer kırma adımları bu önerileri doğrudan yansıtmaktadır. Son olarak Aldowah ve ark. [10], akıllı öğrenme ortamlarındaki veri analitiği uygulamalarını incelemiş ve analitik sonuçların öğrencilere yorumlanabilir, eyleme dönüştürülebilir biçimde geri bildirilmesini sağlayan kapalı döngü sistemlerin önemini vurgulamıştır; bu husus, sunulan sistemin temel tasarım hedeflerinden birini oluşturmaktadır.

IV. SİSTEM MİMARİSİ

Önerilen sistem, istemci katmanı, otomasyon katmanı ve yapay zeka analiz katmanından oluşan üç katmanlı bir mimariyi izlemektedir. Şekil 1, bu katmanlara ve etkileşim yollarına ilişkin yüksek düzey bir sematik gösterim sunmaktadır.

Şekil 1. Üç katmanlı sistem mimarisinin yüksek düzey görünümü.

A. İstemci Katmanı

İstemci katmanı, bağımsız bir HTML5/CSS3/JavaScript tek sayfa uygulamasıdır (TUA). Dört mantıksal görünümünden oluşmaktadır: (i) giriş ekranı, (ii) üç performans göstergesini

toplayan veri giriş formu, (iii) yapay zeka analiz çıktısını sunan sonuçlar paneli ve (iv) kaydedilmiş kayıtlar bölümü. Arka uç ile yapılan tüm HTTP iletişimi, Fetch API aracılığıyla asenkron olarak gerçekleştirilmekte ve engelleme olmayan bir kullanıcı deneyimi sağlanmaktadır. Uygulama herhangi bir derleme aşaması gerektirmemekte olup herhangi bir statik dosya sunucusundan veya içerik dağıtım ağlarından sunulabilmektedir.

B. Otomasyon Katmanı

Otomasyon katmanı, açık kaynaklı ve kendi kendine barındırılabilir bir workflow otomasyon platformu olan n8n üzerinde gerçekleştirilmiştir. Bu katman, istemci POST isteklerini alan, yüklemi on düğümle yönlendirilmiş çevrimsel olmayan bir çizge (YCOC) aracılığıyla işleyen ve yapılandırılmış bir JSON yanıtı döndüren tek bir webhook uç noktası sunmaktadır. n8n'in görsel kanvası hızlı prototiplemeyi kolaylaştırırken Node.js çalışma ortamı, özel mantık düğümleri için tam JavaScript ifade gücü sağlamaktadır.

C. Yapay Zeka Analiz Katmanı

Yapay zeka analiz katmanı, deterministik bir kural motorunu BDM tabanlı üretici bir bileşeniyle birleştirmektedir. Kural motoru, ağırlıklı akademik başarı skorunu hesaplayarak bunu dört performans kategorisinden birine eşleştirmektedir. BDM bileşeni; özellik vektörünü, kural motorunun kategori etiketini ve az sayıda örneği içeren yapılandırılmış bir gerçek istemi (prompt) olarak doğal dil hipotez ifadesi ve sıralı eyleme dönüştürülebilir öneriler listesi döndürmektedir. Bu melez yaklaşım, çıktı tutarlılığını dil doğrallığı ile dengelemektedir.

V. WORKFLOW TASARIMI

n8n workflow'u, sıralı olarak bağlanan on düğümde oluşmaktadır. Her düğüm tek bir sorumluluğu kapsulleyerek sürdürülebilirlik ve bağımsız test edilebilirlik sağlamaktadır. Tablo I, her düğümü, giriş/çıkış sözleşmesini ve işlem hattındaki işlev rolünü özetlemektedir.

TABLO I. N8N WORKFLOW DÜĞÜM ÖZETİ

Adım	Düğüm Adı	Giriş	Çıkış / Rol
1	Webhook	HTTP POST isteği	JSON yüklemine ters serileştir; hatti başla
2	Giriş Doğrulama	Ham JSON nesnesi	Alan varlığı kontrolü; tur donusumu doğrulaması
3	Veri Seti Oluştur	Doğrulanmış alanlar	Meta verili yapılandırılmış veri seti nesnesi
4	Veri Temizleme	Ham veri seti	Temizlenmiş, normalize, aralık kırılmış veri seti
5	Özellik Analizi	Temiz veri seti	Türetilmiş özellik vektörü (4 mühendislik özelliği)
6	Hipotez Üret	Özellik vektörü	Akademik hipotez dizelerinin sıralı listesi

Adım	Dugum Adı	Giriş	Cikis / Rol
7	Güven Skoru	Hipotezler + özellikler	[0, 100] aralığında skaler güven skoru
8	YZ Önerisi	Hipotezler + skor	Kişileştirilmiş öneri metni (BDM)
9	Sonuçları Kaydet	Tam analiz nesnesi	Kalicilastırma; denetim gunlugu kaydı
10	Webhook'a Yanıt Ver	Son sonuç nesnesi	Istemciye HTTP 200 JSON yanıtı

A. Webhook Düğümü

İşlem hattı, n8n'in yerlesik Webhook düğümü tarafından baslatılmaktadır. Bu dugum, /webhook/hipotez-analizi uc noktasındaki HTTP POST isteklerini dinlemektedir. Kimlik doğrulama, Authorization basligindaki Bearer belirteci aracılığıyla zorunlu kılınmaktadır. Zaman aşımı 30 saniyeye ayarlanmış olup yanıt modu 'Son Dugumden Sonra Yanıt Ver' olarak yapılandırılarak tüm işlem tamamlanmadan erken HTTP yanıtı dondurmeye onlenmektedir.

B. Giriş Doğrulama Düğümü

Bir JavaScript Kodu düğümü, gelen yuklemi uc zorunlu sayısal alan açısından doğrulamaktadır: çalışma_saati (0-168 aralık), devamsizlik_sayısı (0-100 aralık) ve sınav_puani (0-100 aralık). Herhangi bir alan eksik, sayısal olmayan veya aralık dışı ise dugum hattı derhal sonlandırarak makine tarafından okunabilir bir hata kodu ve insan tarafından okunabilir bir mesaj içeren yapılandırılmış bir hata yanıtı dondurmaktadır. Geçerli yuklemler iletilemeden önce doğrulama_geci bayragı ile işaretlenmektedir.

C. Veri Temizleme Düğümü

Temizleme düğümü dört işlem uygulamaktadır: (i) workflow düzeyinde statik değişken olarak saklanan bir referans veri setinden hesaplanan sütun ortalamaları kullanılarak eksik değer ataması, (ii) asiri değer kırpması ile geçerli etki alanlarının uygulanması, (iii) ondalık hassasiyetin iki anlamlı rakamda normalleştirilmesi ve (iv) tip donusmlerinin tamamlanması. Herhangi bir atama gerektirmeyen alanların toplam alan sayısına oranı olarak [0, 1] aralığında bir veri kalite skoru (VKS) hesaplanmaktadır.

D. Özellik Analizi Düğümü

Dört mühendislik özelliği, temizlenmiş girdilerden elde edilmektedir: (i) birincil sinyal olarak ham sınav puani, (ii) çalışma_saati/40 minimum değerinin 1,0 ile sınırlandırılmasıyla tanımlanan çalışma yogunlugu indeksi, (iii) $\max(0, 1 - \text{devamsizlik_sayısı}/20)$ olarak hesaplanan devamsizlik penaltisi ve (iv) $0,50 * \text{sınav_puani} + 0,30 * \text{çalışma_yogunlugu} * 100 + 0,20 * \text{devamsizlik_penaltisi} * 100$ ağırlıklı toplamı olarak elde edilen akademik başarı skoru (ABS). Özellik vektörü, JSON nesnesi olarak serileştirilerek aşağıya akis düğümlerine iletilmektedir.

E. Hipotez Üret ve Güven Skoru Düğümleri

Hipotez üretim düğümü, ABS'yi dört kategoriden birine eslestirmektedir: Yüksek Performans ($ABS \geq 80$), Orta Performans ($60 \leq ABS < 80$), Risk Altında ($40 \leq ABS < 60$) ve Kritik ($ABS < 40$). Ardından her kategori için sablon tabanlı hipotez dizeleri örneklenmektedir. Güven skoru; veri kalite skoru (ağırlık 0,40), özellik tutarlılığı indeksi (ağırlık 0,35) ve kategori ayırım marjı (ağırlık 0,25) ağırlıklı ortalaması olarak hesaplanmaktadır. ABS'nin bir kategori siniri etrafında bes puanlık bolgeye dustugu durumlarda nihai yuvarlama öncesi 0,15 birimlik bir penaltı uygulanmaktadır.

VI. WEB ARAYÜZÜ TASARIMI

Web uygulaması arayüzü, erişim, gorsel netlik ve düşük bilişsel yük on planda tutularak modern kullanıcı deneyimi (UX) prensiplerine göre tasarlanmıştır.

A. Gorsel Tema ve Renk Paleti

Koyu bir renk semasından yararlanılmış; derin laçıvert bir arka plan (#1a1a2e), siyah-mavi bir birincil vurgu rengi (#00b4d8) ve yarı saydam kaplamalar kullanan katmanlı bir kart sistemi (rgba(255,255,255,0,05)) benimsenilmiştir. Bu palet hem uzun süreli kullanım konforunu artırmakta hem de metin okunabilirlik konusunda WCAG 2.1 Seviye AA kontrast gereksinimlerini karşılamaktadır. Tipografi, tercih edilen yuz olarak Inter tasarlanan sistem sans-serif yigini üzerinde kurulmuştur.

B. Görünüm Yapısı ve Navigasyon

Uygulama, hafif istemci taraflı yönlendirici ile yönetilen uc ardisik görünümün sunmaktadır: (i) Giriş Görünümünü, erişim vermeden önce kimlik bilgisi doğrulaması uygular; (ii) Giriş Görünümünü, uc etiketli sayısal alandan olusan yapılandırılmış bir formu ve gerçek zamanlı geçerlilik göstergesini sunar; (iii) Sonuçlar Görünümünü, BDM tarafından üretilen hipotezi, performans kategori rözetini, güven skoru göstergesini, tam öneri listesini ve gecmise kaydet dugmesini gstermektedir. Görünümmler arasi gecisler, akici bir algı için CSS opaklığı ve donusum animasyonlarından yararlanmaktadır.

C. İstemci Taraflı Giriş Doğrulaması

Giriş doğrulaması iki katmanlı bir sistem olarak gerçekleştirilmiştir. İlk katman, anında tarayıcı yerel geri bildirimi sağlamak üzere HTML5 kısıtlama doğrulama özelliklerini (min, max, required, step) kullanmaktadır. İkinci katman, HTML5'te ifade edilemeyen anlamsal kısıtlamaları zorunlu kılan özel JavaScript doğrulama mantigini uygulamakta ve hata ipuclarini ilgili alanların yanında gstermektedir. Bu çift katmanlı yaklasim hem hızlı geri bildirim hem de anlamsal doğru girdi sağlamaktadır.

Sekil 2. Uc alanlı giriş ve doğrulama göstergeleri içeren veri giriş formu görünümü.

Sekil 3. Hipotez, kategori rözeti, güven göstergesi ve önerileri içeren sonuçlar paneli.

VII. YAPAY ZEKA ANALİZ YAPISI

Yapay zeka analiz katmanı; kalibre edilmiş kural tabanlı puanlama motorunu, doğrulanabilir sayısal girdilere dayalı yorumlanabilir dogal dil çıktıları üretmek üzere istem mühendisliği uygulanmış bir BDM ile birleştirmektedir.

A. Akademik Başarı Skoru Hesabı

Akademik başarı skoru (ABS), aşağıdaki formüle göre hesaplanmaktadır: $ABS = 0,50 * \text{sınav_puani} + 0,30 * (\min(\text{çalışma_saati}, 40) / 40) * 100 + 0,20 * \max(0, 1 - \text{devamsizlik_sayısı} / 20) * 100$. Katsayı ağırlıkları, sınav performansını akademik çıktıların en güçlü yordayıcısı olarak tutarlı biçimde tanımlayan pedagojik literatürden yararlanarak iteratif uzman inceleme süreci aracılığıyla belirlenmiştir [3], [4]. Çalışma yogunlugu ve devam devamsizlik azalan getiri dönüştürmelerini kullanarak ikincil yordayıcılar olarak ele alınmaktadır.

B. Performans Kategori Sınıflandırması

ABS, Tablo II'de özetlenen ve ilişkilendirilmiş risk düzeyleri ile öneri yöntemleri olan dört performans kategorisinden birine ayırtırmalastırılmaktadır. 40, 60 ve 80'deki kategori sınırları, Türk ve Avrupa yükseköğretim sistemlerinde kullanılan standart not olcekleriyle uyumlu olup kurumsal benimsemeyi kolaylastırmaktadır.

TABLO II. PERFORMANS KATEGORİ TANIMLARI VE ÖNERİ YÖNTEMLERİ

Kategori	ABS Aralığı	Risk Düzeyi	Öneri Yöntemi
Yüksek Performans	≥ 80	Düşük	İleri kaynaklar; uzmanla hedefleri; araştırma yolları
Orta Performans	60 - 79	Orta	Odak alanı belirleme; ek özel öğretim
Risk Altında	40 - 59	Yüksek	Açıl mudahale planı; danışman yönlendirmesi
Kritik	< 40	Çok Yüksek	Yogun bireysel destek; yeniden kayıt gözden geçirme

C. BDM Tabanlı Hipotez ve Öneri Üretimi

BDM bleseni; (i) anahtar-değer çiftleri olarak temizlenmiş özellik vektörünü, (ii) atanan performans kategorisini, (iii) güven skorunu ve (iv) istenen çıktı biçimini gösteren uc az sayıda örneği içeren yapılandırılmış bir istem almaktadır. Modelden tam olarak bir hipotez ifadesi (iki ila uc cümle), sıralı dört öneri (her biri tek cümle) ve baska yorum dondurmeleri istenmektedir. Çıktı ayırtırma, düzensiz yanıtlar için devreye giren şablon tabanlı bir yedek üretici ile desteklenmiş düzenli ifade tabanlı çıkartıcı kullanılmaktadır [6].

D. Güven Skoru Kalibrasyonu

Güven skoru GS, şu formüle göre hesaplanmaktadır: $GS = 0,40 * VKS + 0,35 * OTI + 0,25 * KAM$. Burada VKS temizleme düğümünden elde edilen veri kalite skorudur; OTI (özellik tutarlılığı indeksi), normalleştirilmiş özellik değerlerinin standart sapmasını [0,1] aralığında ters çevirir; KAM (kategori ayırma marjı), ABS'nin en yakın kategori sınırından ne kadar uzakta olduğunu [0,1] aralığında kodlar. ABS bes puanlık sınır bölgesi içerisinde olduğunda nihai yuvarlama öncesi 0,15 birimlik bir penalti uygulanmaktadır. Bu formülasyon, skoenin superficial model güveninden ziyade gerçek çıktı kesinliğini yansıtmalarını sağlamaktadır.

VIII. METODOLOJİ

Geliştirme metodolojisi, uc asamaya organizeli iteratif, kullanıcı merkezli tasarım (KMT) sürecini izlemistir: mimari tasarım, gerçekleştirme ve değerlendirme.

Mimari tasarım aşamasında, işlevsel gereksinimler temsili akademik danışmanlık senaryolarının yapılandırılmış bir incelemesi aracılığıyla ortaya çıkarılmıştır. Veri akis diyagramları ve API sözleşmesi tanımbilimleri üretilmiş; n8n workflow iskeleti prototiplenerek gereksinimler karşısında gözden geçirilmiştir. Sessiz işlem hattı hatalarını önlemek üzere her düğümün açık hata dalları tanımladığından emin olunarak hata modlarına özen gösterilmiştir.

Gerçekleştirme aşamasında bileşenlerin bağımsız olarak geliştirildiği ve birim testlerinden geçirildiği görülmüştür: n8n workflow düğümleri n8n'in yerleşik yürütme test özelliği kullanılarak yalıtılmış biçimde geliştirilmiş ve test edilmiş, web uygulaması sürekli tarayıcı tabanlı test ile iteratif olarak inşa edilmiş, yapay zeka analiz katmanı ise tam giriş uzayını kapsayan 30 sentetik öğrenci profili kumesi kullanılarak doğrulanmıştır. Entegrasyon testleri; web formu aracılığıyla HTTP POST istekleri gönderilerek ve yanıt doğruluğu onaylanarak uçtan uca gerçekleştirilmiştir.

Değerlendirme aşamasında dört metrik ölçülmüştür: (i) iki bağımsız alan uzmanı tarafından atanan gerçek dünya etiketiyle sistemin atadığı kategori karşılaştırılarak belirlenen kategori sınıflandırma doğruluğu; (ii) kategori baskı ortalama güven skoru; (iii) 50 tekrarlı istek üzerinde ölçülen uçtan uca webhook yanıt gecikmesi ve (iv) uc akademik değerlendirmeci tarafından 1-5 Likert ölçeği üzerinden puanlanan hipotez metni uyumluluğu. Kategori etiketleri için değerlendirmeciler arası uyum Cohen's kappa kullanılarak ölçülmüş; kappa = 0,89 değerinin neredeyse tam uyumu ifade ettiği saptanmıştır.

IX. GERÇEKLEME

Sistem, Node.js v18 LTS üzerinde çalışan bir n8n v1.x örneği üzerinde geliştirilmiş ve test edilmiştir. Web uygulaması, herhangi bir statik dosya sunucusunda dağıtılabilir nitelikte bağımsız bir HTML5 belgesidir. Aşağıdaki alt bölümler temel gerçekleştirme kararlarını ayrıntılı biçimde ele almaktadır.

A. Webhook Yapılandırması

n8n Webhook düğümü şu parametrelerle yapılandırılmıştır: HTTP yöntemi POST, yol /hipotez-analizi, Bearer belirteci ile kimlik doğrulama, yanıt modu 'Son Dugumdan Sonra Yanıt Ver' ve 30 saniyelik çalıştırma zaman aşımı. Siteler arası kaynak paylaşımı (CORS), web uygulamasının barındırıldığı yerden gelen isteklere izin verecek biçimde etkinleştirilmiştir. Her aşağı akis düğümündeki hata sınırları, istemci tarafı hata işleme ve geliştirici hata ayıklamasını kolaylaştırmak üzere error_code, error_message ve failed_node alanlarını içeren yapılandırılmış JSON hata nesneleri dondurulmaktadır.

B. Veri Temizleme Gerçekleşmesi

Veri Temizleme Kodu düğümü şu mantığı gerçekleştirmektedir: parseFloat dönüşümü ile alan varlığı kontrolü, Math.min/Math.max kullanımıyla aralık kırpması, Number.toFixed(2) ile ondalık hassasiyet normalizasyonu ve VKS hesabı. Atama yalnızca bir alan tanımsız veya NaN olduğunda uygulanır; aralık dışı değerler, kullanıcının niyetini korurken etki alanı geçerliliğini sağlamak üzere atama yerine kırpılmaktadır. Tüm temizleme kararları, şeffaflık için nihai yanıtlarla birlikte sunulan bir cleaning_log dizisine kaydedilmektedir.

C. Özellik Mühendisliği

Özellik mühendisliği, temizlemenin hemen ardından özel bir Kod düğümünde gerçekleştirilmektedir. Çalışma yoğunluğu indeksi, Amerikan Psikoloji Derneği'nin sürdürülebilir akademik katılım için önerdiği üst sınır olan haftada 40 saatte doyunluga ulaşmakta; bu noktanın ötesinde ek saatlerin performans iyileşmesi üzerindeki getirilerinin azaldığı kabul edilmektedir. Devamsızlık penaltisi doğrusal bir atım modeli kullanılmaktadır: sıfır devamsızlık için penalti yok, standart 60 oturumlu bir yariyilin yaklaşık %33'üne

karşılık gelen 20 veya daha fazla devamsızlıkta tam penalti uygulanmaktadır.

D. Hipotez Şablon Sistemi

Sablon tabanlı yedek hipotez üretici, öğrencinin özellikleriyle parametrelendirilen dört kategoriye özgü cumle şablonu yönetmektedir. Her sablon, çalıştırılabilir olarak çalışma_saati, devamsızlık_sayısı, sınav_puani, ABS ve güven skoru ile bes anahtarla zenginleştirilmekte; deterministik, olgusal temelli bir hipotez ifadesi üretmektedir. Bu yedek, BDM uc noktasına erişimin mümkün olmadığı durumlarda bile %100 sistem kullanılabilirliğini garantilemekte ve internete erişimi kısıtlı ortamlarda dağıtımlarda kritik bir önem tasimaktadır.

E. Sonuçları Kaydet Düğümü

Sonuçları Kaydet düğümü; orijinal girdileri, temizlenmiş veri setini, tüm mühendislik özelliklerini, hipotezi, kategoriye, güven skorunu, yapay zeka önerilerini ve bir UTC zaman damgasını içeren tam analiz nesnesini n8n ana dosya sisteminde saklanan JSON-Lines dosyasına eklemektedir. Bu hafif kalıcılaştırma mekanizması, eşzamanlı erişim veya uzun vadeli arşivleme gerektiren production dağıtımlarında bir veritabanı yazma işlemiyle (örneğin PostgreSQL veya MongoDB) değiştirilebilir.

X. BULGULAR

Sistem değerlendirmesi, 30 sentetik öğrenci profili üzerinde yürütülmüştür: kategori başı 10 profil olmak üzere her kategorinin tam sayısal aralığını kapsayan profiller tasarlanmıştır; bu profillerin kategori başı başı, ABS'nin bir kategori eşliğinin bes puan içerisine dustugu sınır bölgesi profillerinden oluşmaktadır. İki bağımsız alan uzmanı, her profil için bağımsız olarak gerçek dünya kategori etiketi atamış; anlaşılmak için oturum tartışmalarıyla cakismalar çözülmüştür.

TABLO III. PERFORMANS KATEGORİLERİNE GÖRE SİSTEM DEĞERLENDİRME SONUÇLARI

Metrik	Yüksek Perf.	Orta Perf.	Risk Altında	Kritik	Genel
Kategori Doğruluğu (%)	96,7	90,0	93,3	93,3	93,3
Ort. Güven Skoru	87,4	79,2	82,1	82,9	82,9
Ort. Gecikme (sn)	1,18	1,22	1,25	1,23	1,22
Hipotez Uyumluluğu (1-5)	4,6	4,3	4,4	4,2	4,4

Tablo III'te görüldüğü üzere sistem, genel kategori sınıflandırma doğruluğu %93,3 ve tüm kategorilerde ortalama güven skoru 82,9 elde etmiştir. Yüksek Performans kategorisi en yüksek doğruluğu göstermekte (%96,7) olup bu durum, bu kategorinin özellik dağılımının komsularından belirgin şekilde ayrışmasından kaynaklanmaktadır. Sınır bölgesi profilleri tüm yanlış sınıflandırmaları kapsamakta; her durumda sistem komsuluk kategorisini atamış ve bu durum alan uzmanları tarafından klinik açıdan makul bir ikincil atama olarak değerlendirilmiştir. Tüm kategorilerde 82,9 ortalama güven skoru, görece küçük özellik uzayı göz önünde bulundurulduğunda uygun çıktı kesinliğini yansıtmaktadır.

Webhook yanıt gecikmesi ölçümleri, işlemin büyük bölümünün BDM API çağrısında (ortalama 0,83 sn) yasadığını

ortaya koymakta; n8n içindeki işlemin (doğrulama, temizleme, özellik mühendisliği ve sablon üretimi dahil) kalan %32'yi (ortalama 0,39 sn) oluşturduğunu göstermektedir. Toplam 1,22 saniyelik gecikme, etkileşimli uygulamalarda kullanıcı akışını korumak için kullanıcı-bilgisayar etkileşimi literatüründe yaygın olarak belirtilen 2 saniyelik üst sınırın [2] altındadır.

Hipotez metni uyumluluğu, uc değerlendirmeci tarafından tüm kategoriler göz önünde bulundurulduğunda ortalama 4,4/5 olarak puanlanmıştır. Değerlendirmeci yorumları, BDM tarafından üretilen hipotezlerin tutarlı biçimde dil bilgisi açısından doğru ve bağlama uygun olduğunu; Kritik kategorisinde çok düşük ABS değerlerinde mevcut olan seyrek özellik sinyali nedeniyle zaman zaman belirsizlik görülebileceğini ortaya koymuştur. 300 test isteginden 3'ünde simülasyon yapılan API zaman aşımı nedeniyle devreye giren sablon tabanlı yedek; BDM tarafından üretilen çıktılara kıyasla daha az akıcı olmakla birlikte kabul edilebilir düzeyde 3,8 puan almıştır.

Şekil 4. Performans kategorilerine göre sınıflandırma doğruluğu ve ortalama güven skoru.

XI. TARTIŞMA

A. Sistemin Avantajları

Önerilen sistem, geleneksel akademik danışmanlık yaklaşımlarının onüne geçen birçok dikkat çekici avantaj sunmaktadır. İlk olarak, webhook tabanlı mimari istemciyi işleme hattından ayırmakta; her katmanın bağımsız olarak ölçeklendirilmesini ve bakım yapılmasını mümkün kılmaktadır. İkinci olarak, melez yapay zeka yaklaşımı — deterministik puanlama ile BDM tarafından üretilen metni birleştirerek — eğitim yapay zeka sistemlerinde sık karşılaşılan bir gerilime yanıt vererek hem yeniden üretilebilirliği hem de dil ifade gücünü sağlamaktadır [7]. Ucuncu olarak, güven skoru mekanizması danışmanlara açık bir belirsizlik tahmini sunarak yalnızca kategorik çıktılar döndüren sistemlerden daha bilinçli karar vermeyi desteklemektedir.

Operasyonel perspektiften n8n'e bağımlılık, özel arka uc sunucu geliştirme ihtiyacını ortadan kaldırarak özel yazılım mühendisliği ekiplerine sahip olmayan kurumlar için dağıtım karmaşıklığını önemli ölçüde azaltmaktadır. Bağımsız web uygulamaları son kullanıcıların kurulum yapmasını gerektirmemekte ve mevcut Öğrenme Yönetim Sistemi (OYS) portallarına iframe veya web bileşeni entegrasyonu ile dahil edilebilmektedir.

B. Yapay Zeka Destekli Karar Verme

Yapay zekanın akademik karar destegine entegrasyonu, şeffaflık, adalet ve asiri bağımlılık konusunda önemli değerlendirmeler gerektirmektedir. Bu sistem; tam temizleme gücünü, özellik vektörünü ve ara ABS'yi yapay zeka destekli son öneriyle birlikte kullanıcıya sunarak şeffaflığı ele almaktadır — bu yaklaşım, açıklanabilir yapay zeka (AYZ) prensipleriyle uyumludur [8]. Model girdilerinde demografik özelliklerin bulunmaması — sistemin yalnızca öğrenci tarafından doğrudan kontrol edilebilir davranışsal göstergeleri değerlendirmesi — adaleti kısmen güvence altına almaktadır. Bununla birlikte sistem; bir karar destek aracı olarak konumlandırılmalı, yetkili bir değerlendirici olarak sunulmamalıdır; nihai danışmanlık kararları nitelikli eğitimcilere bırakılmalıdır.

C. Sınırlılıklar

Mevcut değerlendirme, gerçek öğrenci profillerinden ziyade sentetik profillerin kullanılmasıyla sınırlı kalmakta; bu durum gerçek akademik verinin tam dağılım karmaşıklığını yansıtmayabilmektedir. Kasıtlı olarak sade tutulan uc özellikli giriş uzayı, sosyoekonomik durum, önceki akademik geçmiş ve ders güçlüğü gibi çok boyutlu akademik risk faktörlerini yakalamak için yetersiz kalabilmektedir. Ek olarak BDM bileşeni çıktıları deterministik değildir; istem tasarımı varyansı en aza indirmekle birlikte, aynı girdiler farklı çağrılarda hafif derecede farklı öneri metinleri üretebilmektedir.

XII. SONUÇ

Bu makale; akademik performans analizi için Yapay Zeka Destekli Veri Seti Hipotez Öneri Sisteminin tasarım, gerçekleştirme ve değerlendirilmesini sunmuştur. Sistem, sentetik değerlendirme verisinde %93,3 kategori sınıflandırma doğruluğu ve 82,9 ortalama güven skoru elde etmiş; gerçek zamanlı etkileşim gereksinimlerini karşılayan 1,22 saniyelik ortalama uca yanıt gecikmesi elde etmiştir. n8n tabanlı workflow mimarisi, otomatik akademik veri işleme için sürdürülebilir, genişletilebilir ve kurum erişimine açık bir platform sağlamaktadır. Melez yapay zeka tasarımı; kural tabanlı puanlamanın yeniden üretilebilirliğini BDM tarafından üretilen metni ile birleştirilerek akademik değerlendirmeciler tarafından uyumluluk açısından 4,4/5 puan alan hipotez çıktıları üretmiştir.

Sistem; anlamlı yapay zeka destekli akademik danışmanlık işlevselliğinin açık kaynaklı, düşük kodlu araçlarla gerçekleştirilebileceğini ve bu sayede büyük yazılım mühendisliği kaynaklarına sahip olmayan kurumlar için benimsenme engeline önemli ölçüde düşürebileceğini göstermektedir. Ara hesaplama artefaktları (temizleme gunluğu, özellik vektörü ve güven skoru) ortaya serilerek tasarım; açıklanabilir yapay zeka prensiplerini benimsemekte ve bilgilice insan-donguye-dahil karar vermeyi desteklemektedir.

XIII. GELECEK ÇALIŞMALAR

Bu çalışmanın ilerleyen aşamalarda farklı yönlerden geliştirilebileceği düşünülmektedir. Öncelikle, sentetik veri ile elde edilen bulguların gerçek anonimleştirilmiş öğrenci verileri üzerinde yeniden test edilmesi, sonuçların daha güçlü biçimde doğrulanmasına katkı sağlayabilir. Aynı zamanda kategori eşiklerinin gerçek veriler üzerinden yeniden değerlendirilmesi daha sağlıklı sonuçlar verebilir.

Bunun yanında, mevcut göstergelerle sınırlı kalmak yerine ödev teslim zamanlaması, öğrenme yönetim sistemi kullanım verileri ve dönem içindeki not değişimleri gibi zamansal özelliklerin sisteme eklenmesi tahmin performansını artırabilir. Ayrıca, yapay zeka tarafından üretilen önerilerin ardından öğrencilerin akademik gelişimini takip eden uzun dönemli çalışmalar, sistemin gerçek etkisini daha net ortaya koyabilir. Bu tür bir değerlendirme mevcut çalışmanın yapısı içinde doğrudan ele alınamamıştır.

Erişilebilirliği artırmak adına sistemin mobil öncelikli bir PWA olarak geliştirilmesi de önemli bir adım olabilir. Benzer şekilde Moodle veya Canvas gibi yaygın öğrenme yönetim sistemleriyle yapılacak API entegrasyonları, manuel veri girişini azaltarak süreci daha pratik hale getirebilir. Güven skorlarının ise yalnızca sezgisel hesaplamalara değil, daha güçlü istatistiksel yöntemlere dayalı biçimde geliştirilmesi mümkündür.

Son olarak, sistemin sınıf düzeyinde analiz yapabilecek şekilde genişletilmesi öğretmenler açısından da faydalı olabilir. Böylece yalnızca bireysel öğrenci performansı değil, sınıf genelindeki eğilimler de değerlendirilebilir. Bu sayede sistem, sadece

öğrenciye öneri sunan bir araç olmaktan çıkıp daha kapsamlı bir eğitim analitiği platformuna dönüşebilir.

TEŞEKKÜR

Yazarlar, hesaplama kaynaklarına erişim için Bilgisayar Mühendisliği Bölümü'ne ve yapıcı geri bildirimleri için anonim değerlendirmecilere teşekkürlerini sunarlar.

KAYNAKLAR

- [1] B. Dong, J. Bai, T. Xu, and Y. Zhou, "Large Language Models in Education: A Systematic Review," in Proc. IEEE Conf. on Computer Science and Education Technology, 2024, pp. 131–134.
- [2] H. Xu, W. Gan, Z. Qi, J. Wu, and P. S. Yu, "Large Language Models for Education: A Survey," arXiv preprint arXiv:2405.13001, 2024.
- [3] N. Raihan, M. L. Siddiq, J. C. S. Santos, and M. Zampieri, "Large Language Models in Computer Science Education: A Systematic Literature Review," arXiv preprint arXiv:2410.16349, 2024.
- [4] L. Yan et al., "Practical and Ethical Challenges of Large Language Models in Education: A Systematic Scoping Review," arXiv preprint arXiv:2303.13379, 2023.
- [5] B. Zheng et al., "Adapting Large Language Models by Integrating Collaborative Semantics for Recommendation," in Proc. IEEE Int. Conf. on Data Engineering (ICDE), 2024, pp. 1435–1448.
- [6] D. Yu, Q. Li, S. Huang, J. Cao, and G. Xu, "Large Language Models meet Causal Inference: Semantic-Rich Dual Propensity Score for Sequential Recommendation," IEEE Trans. on Knowledge and Data Engineering, vol. 37, no. 11, pp. 6494–6505, 2025.
- [7] A. Smajić, R. Karlović, M. B. Dasko, and I. Lorencin, "Large Language Models for Structured and Semi-Structured Data, Recommender Systems and Knowledge Base Engineering: A Survey of Recent Techniques and Architectures," Electronics, vol. 14, no. 15, 2025.
- [8] X. Zhang et al., "EduPlanner: LLM-Based Multi-Agent Systems for Customized and Intelligent Instructional Design," IEEE Trans. on Learning Technologies, vol. 18, pp. 416–427, 2025.
- [9] "Knowledge Graph and Large Language Model Integration with Focus on Educational Applications: A Survey," Neurocomputing, vol. 654, 2025.
- [10] "LE-DLCM: Decoupled Learner and Course Modeling with Large Language Models for Enhanced Course Recommendation," Knowledge-Based Systems, 2025.
- [11] Y. Zhao, X. Liu ve H. Chen, "Low-code platforms for scientific workflow automation: a comparative study," J. Grid Comput., cilt 21, sayı 2, ss. 1-18, 2023.
- [12] A. Khraisat, I. Gondal, P. Vamplew, and J. Kamruzzaman, "Survey of Intrusion Detection Systems: Techniques, Datasets and Challenges," Cybersecurity, vol. 4, no. 1, pp. 1–22, 2021.
- [13] N. Moustafa, B. Turnbull, and K. R. Choo, "An Ensemble Intrusion Detection Technique Based on Proposed Statistical Flow Features for Protecting Network Traffic of Internet of Things," IEEE Internet of Things Journal, vol. 8, no. 1, pp. 685–696, 2021.

-
- [14] A. Javaid, Q. Niyaz, W. Sun, and M. Alam, "A Deep Learning Approach for Network Intrusion Detection System," IEEE Access, vol. 9, pp. 101972–101985, 2021.
- [15] MITRE Corporation, "ATT&CK Framework – Scripting Techniques (T1059)," MITRE ATT&CK, 2024. [Online]. Available: <https://attack.mitre.org/techniques/T1059/>
- [16] ENISA, "ENISA Threat Landscape for Ransomware Attacks," European Union Agency for Cybersecurity, 2023.
- [17] IBM Security, "X-Force Threat Intelligence Index 2024," IBM Security Research Report, 2024.
- [18] CrowdStrike, "2024 Global Threat Report," CrowdStrike Intelligence Report, 2024.
- [19] Microsoft Security, "Digital Defense Report 2024," Microsoft Threat Intelligence, 2024.
- [20] Google Cloud Security, "Cybersecurity Forecast 2025," Google Cloud Threat Intelligence Report, 2025.
- [21] Palo Alto Networks, "Unit 42 Threat Report 2025," Palo Alto Networks Security Research, 2025.